

# Görüntü işleme algoritmaları

Görüntü işleme algoritmaları içerisinde birçok yöntem bulunmaktadır. Bunlardan bazıları yapay zeka metodlarının yanı sıra farklı görüntü işleme teknikleri de bulunmaktadır.

Görüntü işleme teknikleri arasında bu yöntemler bulunur:

## 1. Yapay Zeka Tabanlı Görüntü İşleme:

Derin öğrenme yöntemleri (Convolutional Neural Networks, Recurrent Neural Networks), transfer öğrenimi, nesne tanıma, nesne dedektörleri (YOLO, SSD). Yapay zeka tabanlı görüntü işleme, görüntüleri analiz etmek, anlamak ve yüksek düzeyde özelliklerini çıkarmak için yapay zeka tekniklerini kullanır.

Geleneksel görüntü işleme yöntemleri, piksel düzeyinde işlemler yaparken, yapay zeka tabanlı yöntemler, daha yüksek seviyede özelliklerin çıkarılmasına odaklanır. Bu sayede, daha karmaşık ve genel geçer algoritmalar kullanarak nesne tanıma, sınıflandırma, segmentasyon ve diğer görüntü işleme problemlerini çözer.

Derin öğrenme yöntemleri, yapay sinir ağlarını temel alır ve özellikle Convolutional Neural Networks (CNN) yapısı, görüntü işlemede büyük bir başarı elde etmiştir. CNN'ler, görüntülerdeki özellikleri otomatik olarak öğrenmek için özel bir şekilde tasarlanmış katmanlardan oluşur. Bu katmanlar, özellik haritalarını oluşturmak ve sonuçları yorumlamak için öğrenilmiş ağırlıkları kullanır.


CNN'ler, büyük veri setleri üzerinde eğitilerek nesne tanıma, nesne takibi, görüntü sınıflandırma, segmentasyon ve diğer görevlerde yüksek doğruluk elde eder. Makine öğrenmesi teknikleri de görüntü işleme alanında yaygın olarak kullanılır.

Bu teknikler, özellik tabanlı yöntemlere dayanır ve genellikle öğrenme algoritmaları aracılığıyla görüntülerden özelliklerin çıkarılmasına odaklanır. Bu özellikler daha sonra sınıflandırma, tanıma veya diğer görevlerde kullanılır.

Örneğin, Support Vector Machines (SVM), Decision Trees ve Random Forests gibi algoritmalar, görüntü sınıflandırma veya nesne tanıma gibi görevlerde kullanılabilir. Yapay zeka tabanlı görüntü işleme, büyük veri setleri üzerinde öğrenme yapabilen ve genel geçerli sonuçlar üretebilen sistemlerin geliştirilmesine imkan sağlar.

Bu sayede, farklı sektörlerde, örneğin otomotiv, sağlık, güvenlik, robotik ve medikal görüntüleme gibi alanlarda, görüntü işleme problemlerini çözmek için güçlü ve etkili çözümler sunulabilir. Bu yöntemler, daha önce elde edilmesi zor olan sonuçları elde etmek

ve insanların daha doğru ve hızlı kararlar almasını sağlamak için kullanılabilir.



**Figure 3: The Architecture.** Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating  $1 \times 1$  convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution ( $224 \times 224$  input image) and then double the resolution for detection.

## 2. Image Template mathing yöntemi ile görüntü işleme:

Image template matching (görüntü şablon eşleme) yöntemi, bir görüntüde belirli bir şablonun benzerliklerini tespit etmek için kullanılan bir görüntü işleme tekniğidir. Bu yöntem, bir şablon görüntüsünü, başka bir ana görüntü üzerinde kaydırarak veya ölçeklendirerek eşleştirmeye çalışır.

Görüntüdeki ışıklandırma değişiklikleri, görüntü veya örtülme gibi zorluklarla başa çıkma konusunda sınırlamalara sahip olabilir ve daha karmaşık görüntü işleme yöntemlerine kıyasla daha düşük hassasiyete sahip olabilir. Ayrıca, şablonun belirlenmesi ve şablon boyutunun uygun şekilde ayarlanması gibi başlangıç parametrelerinin doğru şekilde seçilmesi önemlidir. Bu nedenle, bazı durumlarda daha sofistike ve özelleştirilebilir yöntemler tercih edilebilir.

Bununla birlikte, gelişmeler yapay zeka tabanlı görüntü işleme yöntemlerinde, özellikle derin öğrenme tekniklerinde, şablon eşleme yöntemlerinin kapsamı genişlemiştir. Örneğin, Convolutional Neural Networks (CNN) kullanılarak, daha karmaşık ve değişkenlik gösteren nesneleri veya desenleri tespit etmek için özel eğitilmiş ağlar geliştirilebilir. Bu ağlar, daha yüksek düzeyde özelliklerin otomatik olarak öğrenilmesini sağlar ve daha yüksek hassasiyet ve genellebilirlik sunabilir.

Derin öğrenme tabanlı görüntü işleme yöntemleri, görüntü tabanlı görevlerde önemli başarılar elde etmiştir. Örneğin, nesne tespiti, nesne takibi, yüz tanıma, görüntü sınıflandırma, segmentasyon ve daha birçok uygulama bu yöntemlerle gerçekleştirilebilir. Derin öğrenme ağları, büyük veri setlerinden otomatik olarak özellikleri öğrenir ve sonuçlarda yüksek doğruluk elde eder. Bununla birlikte, daha karmaşık yapıları ve daha fazla hesaplama gücü gerektirdikleri için daha fazla kaynak gerektirebilirler.

Yapay zeka tabanlı görüntü işleme, görüntü analizi ve anlama konusunda büyük bir potansiyele sahiptir. Özellikle derin öğrenme ve makine öğrenmesi teknikleri ile birleştirildiğinde, daha karmaşık ve gerçek dünya problemlerini çözmek için güçlü ve esnek

bir çözüm sağlar. Bu alandaki araştırmalar ve gelişmeler, görüntü işleme uygulamalarının daha da ileriye taşınmasına katkıda bulunmaktadır.

### 3. Normalized Cross-Correlation (NCC):

Normalize çapraz korelasyon , iki sinyal arasındaki benzerliği ölçmek için kullanılan bir istatistiksel işlemdir. Özellikle görüntü işleme ve desen tanıma alanlarında yaygın olarak kullanılır.


NCC, iki sinyal arasındaki korelasyonun bir ölçüsünü hesaplar ve sonucu  $[-1, 1]$  aralığında normalleştirir. İki sinyal arasındaki ilişkiyi bulmak için iki sinyalin her bir noktasını çarpıp ve ardından tüm çarpımları toplar. Bu, korelasyonun toplamını elde eder.

Normalleştirme adımı, iki sinyalin boyutlarına bağlı olarak farklılık gösterebilir. Genellikle, her iki sinyalin ortalamaları çıkarılır ve ardından standart sapmalarıyla bölmek suretiyle normalleştirme yapılır. Bu, sinyallerin ortalaması ve varyansı arasında bağımsızlığı korur ve  $[-1, 1]$  aralığında bir sonuç elde edilir.

NCC, özellikle görüntü hizalama, nesne takibi, desen eşleme ve görüntü benzerlik ölçümü gibi alanlarda kullanılır. Örneğin, bir görüntü içindeki bir nesneyi başka bir görüntüde bulmak için NCC kullanılabilir. İki görüntü arasındaki benzerlik düzeyini ölçerek, nesnenin konumu ve rotasyonu gibi bilgileri belirlemeye yardımcı olur.

NCC, ayrıca şablon eşleme ve kalıp tanıma gibi uygulamalarda da yaygın olarak kullanılır. Örneğin, belirli bir nesneyi içeren bir şablonun bir görüntü içindeki konumunu bulmak için NCC kullanılabilir.

Bu işlem, sinyaller arasındaki benzerlikleri nicelendirmek için etkili bir yöntem olabilir, ancak bazı durumlarda ölçeklendirme, rotasyon veya gürültü gibi faktörlerden etkilenebilir. Bu nedenle, spesifik uygulama senaryosuna bağlı olarak, farklı benzerlik ölçüm yöntemleri tercih edilebilir.



Dipnot: Proje içerisinde NCC kullanılmıştır çünkü verilen datasette 3 temel renk kullanılmıştır, dolayısıyla bu 3 temel rengi gri tonlarına dönüştürüp normalize ettikten sonra korelasyonu sağlayarak benzerlik hesaplayan bir algoritma oluşturulmuştur.